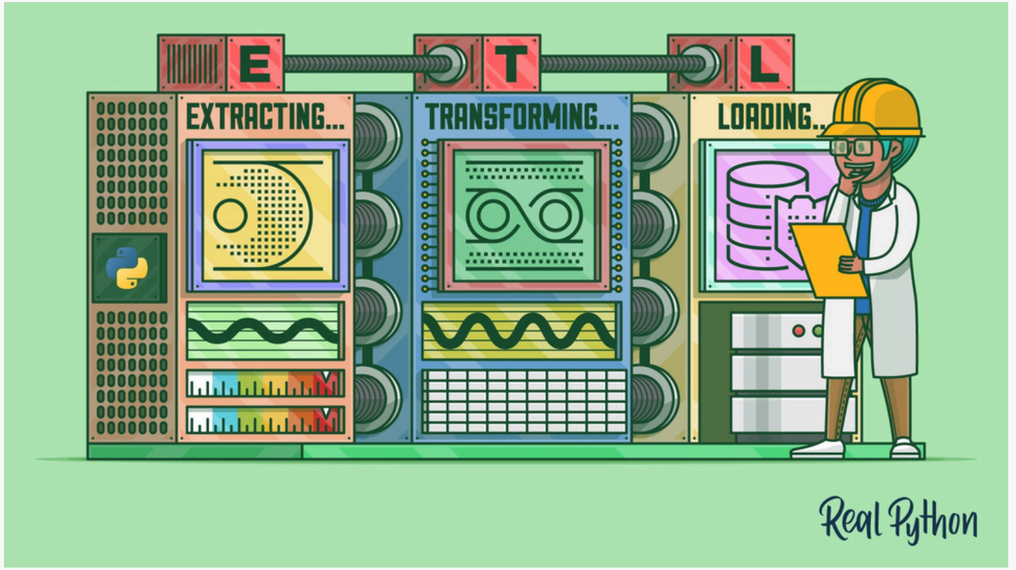
GLOBAL ECONOMIC DATASETS

KELOMPOK 3



THE ROLE OF DATA ENGINEEER

Data Engineer berperan penting dalam merancang dan merawat data arsitektur, mulai dari pemindahan data mentah ke Pentaho untuk cleaning dan transformation hingga menghasilkan data siap analisis. Berbeda dengan Data Analyst dan Data Scientist dari segi fokus, Data Engineer berfokus pada arsitektur dan kesiapan data. Sedangkan Data Analyst fokus pada analisis data dan Data Scientist fokus pada data modeling untuk insights.



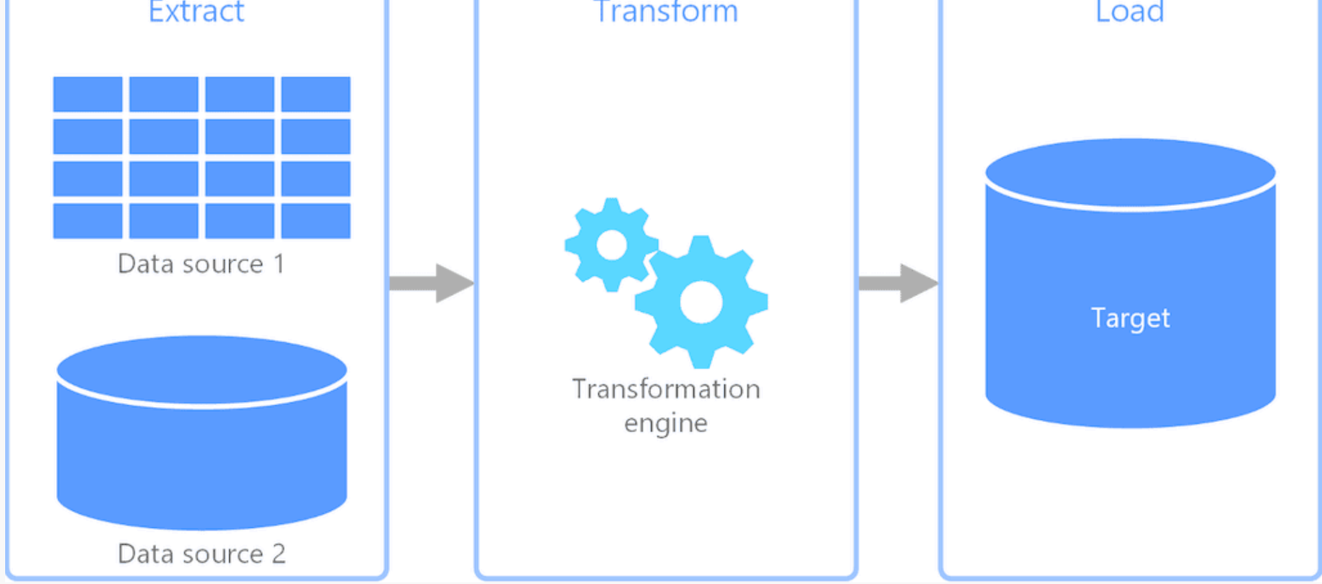
Dalam proyek ini, data pipeline mengubah data inflasi, GDP, dan peace index menjadi dataset terstruktur yang siap digunakan untuk analisis atau model machine learning.

DATASETS

- **Global Income Statistics :** Berisi pendapatan 184 negara dari 1958 - 2015 untuk 184 negara,
- **Global Peace Index (GPI)** : Berisi tingkat perdamaian suatu negara berdasarkan keamanan dan faktor konflik dari 2008 - 2018 untuk 163 negara.
- **Global Inflation Dataset :** Berisi data inflasi tahunan dari 1970 - 2022 untuk 212 negara.



DATA PIPELINE



Pipeline yang digunakan: **ETL (Extract, Transform, Load)**

- Data diekstraksi dari file CSV.
- Dipindahkan ke Pentaho untuk dilakukan transformasi dan cleaning.
- Data yang bersih dan terstruktur kemudian disimpan ke processed layer.

Mengapa pipeline ETL ?

- Cocok untuk data kecil (MB) dan struktur sudah jelas. Berbeda dengan ELT di mana proses transformasi dilakukan setelah data disimpan (lebih cocok untuk big data/cloud).

DATA PIPELINE & ARCHITECTURE

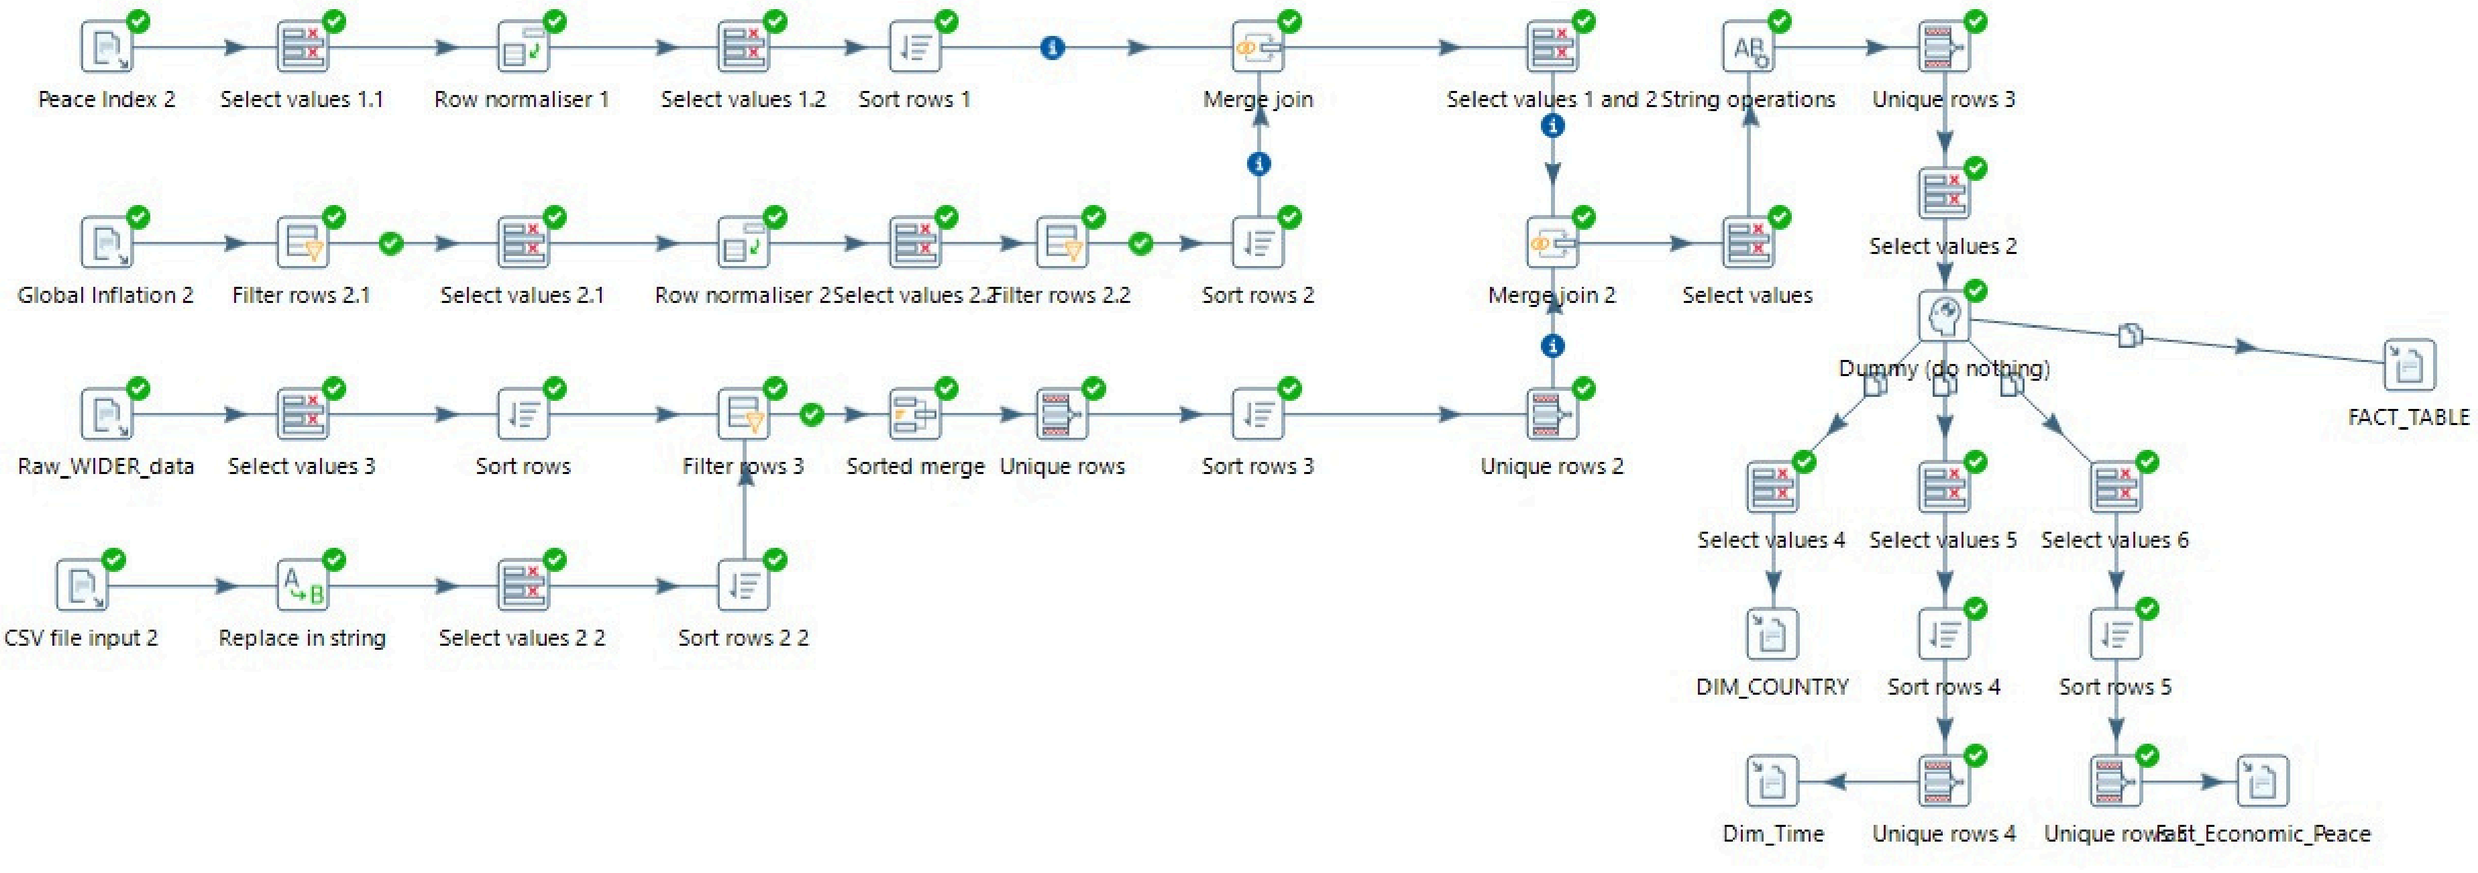
1. Data Generation Layer
   - Data dihasilkan dan diperoleh dari **Kaggle** dalam format CSV.

2. Storage Layer
   - Menggunakan Single Storage dalam bentuk File Storage, di mana data disimpan dalam tiga folder terpisah, berupa file CSV mentah, hasil output Pentaho, dan file logic Pentaho (.ktr dan .kjb).

3. Ingestion Layer
   - CSV File Input: Menghubungkan Pentaho dengan ketiga file CSV mentah.
   - Column Definition: Beberapa format / tipe data kolom disesuaikan agar data dapat diproses dengan konsisten.

DATA PIPELINE & ARCHITECTURE

4. **Transformation Layer:**
   - **Data cleaning and validation**
   - **Join, aggregate, and reshape data**
   - **Data filtering berdasarkan periode waktu**



TRANSFORMATION LAYER

1. Data cleaning and validation

= Menangani missing values (dengan filter data yang ada nilai dan memenuhi format), penyeragaman tipe data, dan menghilangkan nilai numerik dengan awalan 0 (misal 00000012.3 menjadi 12.3)

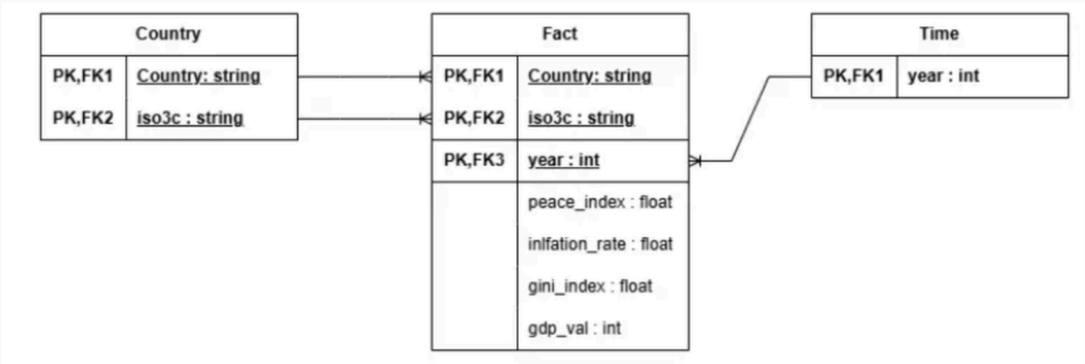
2. Joining, aggregating and reshaping data

= Ketiga dataset digabung dengan “Merge Join” step menggunakan Country dan Year. Selanjutnya, Star Schema diterapkan dengan pembentukan Fact Table (Fact_Economy_Peace) dan dua Dimension Tables (Dim_Country dan Dim_Time).

3. Data filtering berdasarkan periode waktu

= Data dibatasi dari periode 2008 - 2018 untuk memastikan analisis tetap relevan dan data tersedia untuk ketiga dataset tersebut.

RESULT



STAR SCHEMA

#	Country	iso3c
1	AFGHANISTAN	AFG
2	ALBANIA	ALB
3	ALGERIA	DZA
4	ANGOLA	AGO
5	ARGENTINA	ARG
6	ARMENIA	ARM
7	AUSTRALIA	AUS
8	AUSTRIA	AUT

DIM_COUNTRY

#	year
1	2008
2	2009
3	2010
4	2011
5	2012
6	2013
7	2014
8	2015

DIM_TIME

#	Country	iso3c	year	peace_index	inflation_rate	gini_index	gdp_val
1	AFGHANISTAN	AFG	2008	3.153	26.4	29	1268
2	AFGHANISTAN	AFG	2012	3.069	6.4	33	1773
3	AFGHANISTAN	AFG	2017	3.48	5	31	1758
4	ALBANIA	ALB	2008	1.247	3.4	29.98	8986
5	ALBANIA	ALB	2012	1.293	2	28.96	10321
6	ALGERIA	DZA	2012	2.094	9.7	27.62	13226
7	ANGOLA	AGO	2009	1.827	13.7	55	6283
8	ARGENTINA	ARG	2008	1.403	8.6	44.4	18576

FACT_TABLE

Kolom DIM_COUNTRY

- Country: Nama negara.
- iso3c: Kode negara.

Kolom DIM_TIME

- year: Tahun pada data

Kolom FACT_TABLE

- gdp_val: Jumlah output ekonomi negara dibagi populasi (GDP per capita).
- inflation_rate: Laju inflasi suatu barang.
- gini_index: Kesenjangan antara kelompok berpendapatan tinggi dengan rendah.
- peace_index: Mengukur tingkat perdamaian suatu negara / daerah berdasarkan angka kejahatan, konflik militer, dan tingkat keamanan penduduk.

TERIMA KASIH